北京郵電大學
Beijing University of Posts and Telecommunications

论文复现

数据集人口统计偏差

Metrics for Dataset Demographic Bias: A Case Study on Facial Expression Recognition

汇报组：第九组

方向：AI公平性与偏差评估

来源：IEEE TPAMI 2024

论文汇报 | 2026年11月2日

汇报目录

01	论文内容	研究问题、指标体系与主要发现
02	复现工作	数据与实验设计、指标对照及真实模型结果
03	不足与改进	局限分析与重加权探索
04	代码演示	三份Notebook的代码、注释与已完成输出
05	讨论	两个问题及参考答案

总体均衡，仍可能存在类别偏差

A：每种表情都有男女样本

样本数	高兴	愤怒
女性	25	25
男性	25	25

B：性别与表情绑定出现

样本数	高兴	愤怒
女性	50	0
男性	0	50

两套数据都是：100张图片，男女各半，表情各半。

但B可能让模型借助性别去猜表情。

论文做了三件事

01 **整理指标** 把17类已有指标按测量对象分类。

02 **比较指标** 在20个表情数据集上比较，推荐较精简的组合。

03 **检验下游影响** 构造不同偏差的训练集，观察ResNet50的分组表现。

四个推荐指标：定义与含义

ENS：多样性／有效群体数

$$H = -\sum_g p_g \ln p_g, \qquad \mathrm{ENS} = e^H$$

男女各半时ENS=2，仅出现一组时ENS=1。

SEI：已出现群体的均匀程度

$$\mathrm{SEI} = \frac{H}{\ln R}$$

R>1时，比例越均匀越接近1。

V：人口属性与表情的整体关联

$$V = \sqrt{\frac{\chi^2/n}{\min(r-1, c-1)}}$$

χ^2为独立性统计量；V=0表示统计独立。

Z：某个群体×表情的超额或不足

$$\delta = p_{gy} - p_g p_y, \quad Z_{gy} = \delta / d_{gy}$$

$$d_{gy} = \min(p_g, p_y) - p_g p_y \quad (\delta \geq 0)$$

$$d_{gy} = p_g p_y - \max(0, p_g + p_y - 1) \quad (\delta < 0)$$

p为样本比例，R为已出现群体数；n为样本量，r、c为计数表行列数。Z>0为超额，Z<0为不足。

作者怎样分析20个表情数据集

人脸图片

实验室 / 影视 / 互联网

→

FairFace

预测年龄、种族、性别

→

计数表

人口属性 × 表情

由计数表计算偏差，比较不同数据集、不同指标。

人口属性是模型预测值；标签误差也会影响分析结果。

很多指标提供了相近的信息

比较对象	论文中的观察	选择建议
ENS 与熵H	排序相关为1	多样性优先报告ENS
SEI 与1−NSD	排序高度相关	用SEI描述均匀程度
全局关联指标	对数据集的排序相近	优先使用易解释的V

作者推荐：ENS、SEI、V、Z，分别保留不同角度的信息。

用四种设置观察偏差怎样影响模型

实验	训练数据怎样变化
1 整体比例	所有表情中的男女比例一起变化
2 单类偏差	只改变高兴类的男女比例
3 两类反向	高兴偏向女性时，愤怒偏向男性
4 两类同向	高兴与愤怒同时偏向同一群体

11个比例点 × 3次重复；预训练ResNet50，每次训练20轮。

模型受影响的方式，取决于偏差发生在哪里

整体比例变化

原文中，模型对部分整体性别比例变化仍能泛化。

类别内部缺失

某群体在特定表情中缺失时，该类召回率可能明显下降。

类别之间的差异

高兴、愤怒的敏感程度不同；多类偏差也可能影响其他类。

我们复现了统计结果，也实际训练了模型

20

公开数据集的统计分析

17类指标；794,166条记录
60套局部计数与关联矩阵

132

次真实人脸训练

4种设置 × 11个比例点 × 3次
每个模型训练20轮

验证路径：重算指标并对照原文 → 控制训练比例、固定测试集 → 比较分组召回率。

从Kaggle下载压缩数据集，开展图像实验

原始图像包

约122GB

下载与存储成本较高

本次压缩包

259MB

25,262张 · 96×96像素

本次使用的数据样例



标签：高兴



标签：愤怒

处理后：训练14,903张 / 验证4,764张 / 测试2,421张

采用下载包的划分并做文件去重；分辨率、划分与可采样规模和原文不同。

数据来源：fatihkgg/affectnet-yolo-format，第2版 · 图片为本次测试集样例

指标计算与主要统计结果能够重现

1,280

项作者实现对照通过

45 / 45

Fig.3印刷值吻合

21 / 21

Fig.5印刷值吻合

按论文公式计算，并调用作者开源实现逐项核对。

少数局部相关汇总受聚合口径影响；具体差异保留在Notebook中。

怎样评价132次真实训练

保持一致的设置	实际执行
模型与训练轮数	预训练ResNet50；20轮；max_lr=1e−4
采样与重复	11个比例点；每点3个随机种子
测试方式	同一测试集；只评价最后一轮

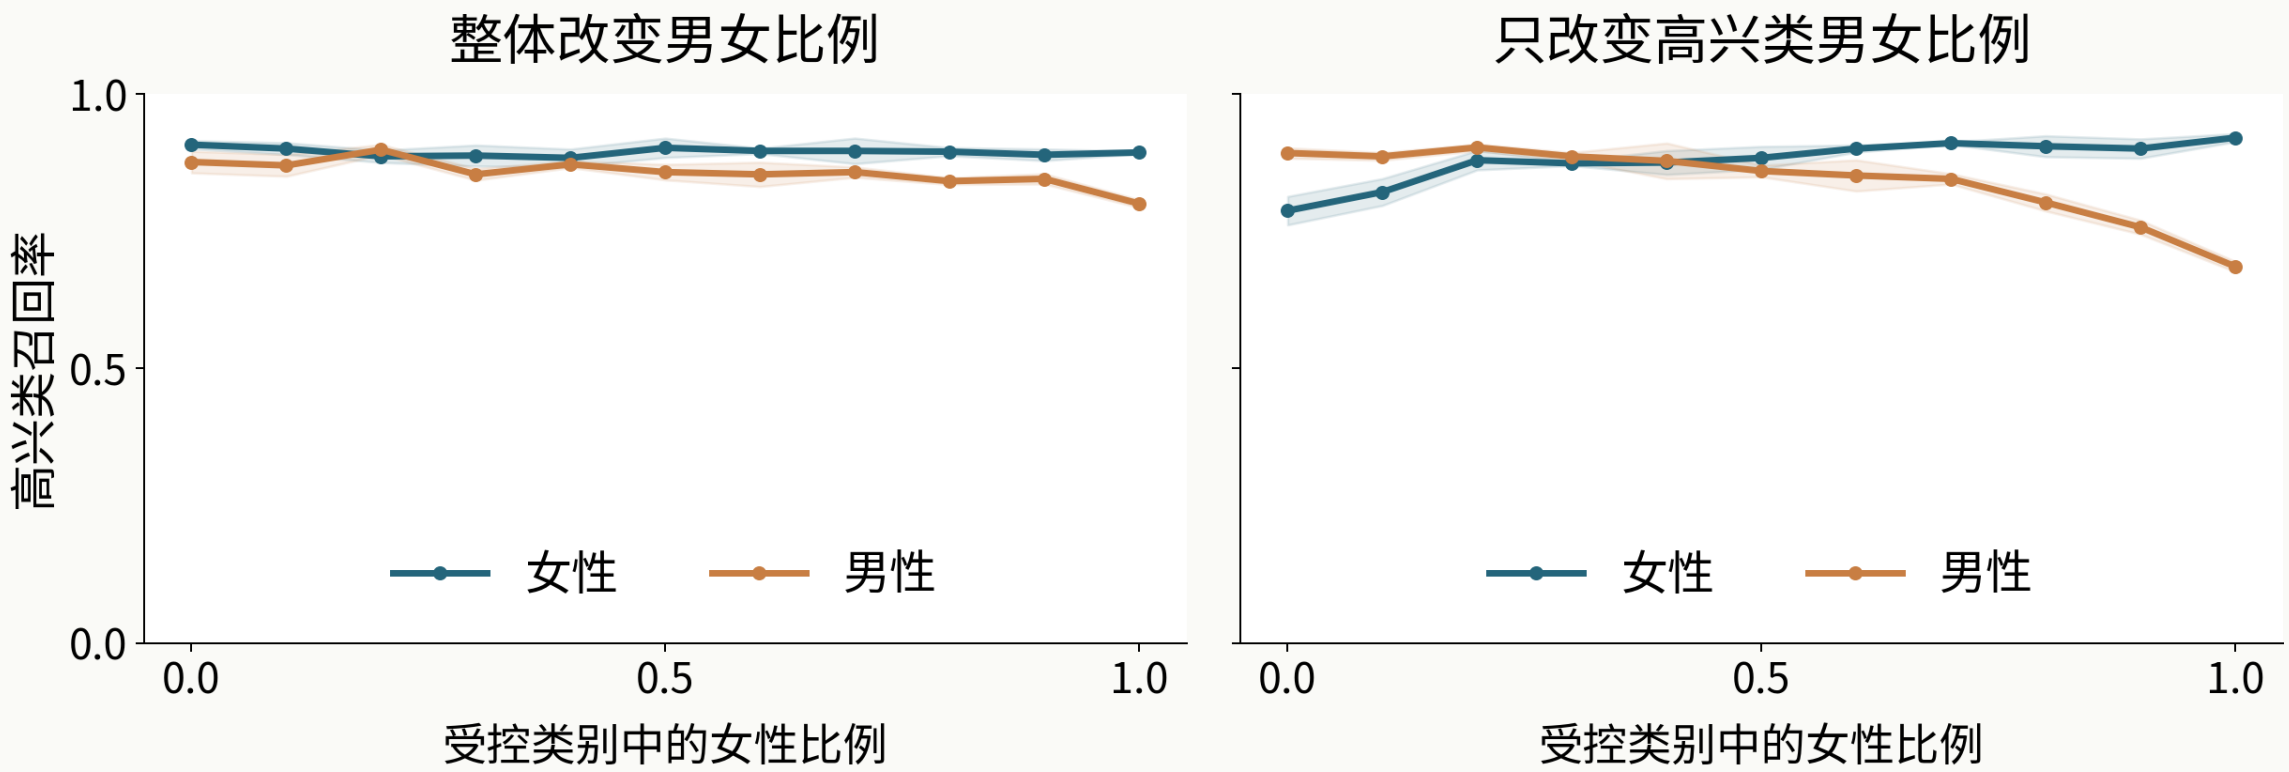
本组采用AdamW、batch=256；原文未明确全部优化细节。

$$\mathrm{Recall}_{g,y} = \frac{TP_{g,y}}{N_{g,y}}$$

$$\mathrm{MacroRecall}_g = \frac{1}{7}\sum_{y=1}^{7} \mathrm{Recall}_{g,y}$$

g为性别组，y为表情类别；N为该组该类测试样本数。分类召回率与七类宏平均同时报告。

类别内部的样本缺失，会影响对应召回率



高兴类中的群体缺失，比单独观察总体男女比例更值得留意。

本组实验1、2 · 三次重复均值；阴影为种子间标准差

主要下降趋势一致，具体降幅有差别

设置	原文AffectNet	本组压缩数据
实验2：女性高兴 均衡 → 该组缺失	>85% → <40%	88.3% → 78.7%
实验3：女性愤怒 均衡 → 该组缺失	约40% → 约10%	48.6% → 16.3%

两项对照都出现下降；实验3降幅接近，实验2下降较温和。

支持论文的定性描述。原文为文字近似值，数据与实验条件并不完全相同。

原文附录A第18、20页；本组为三个重复均值

平均分会掩盖一部分群体损失

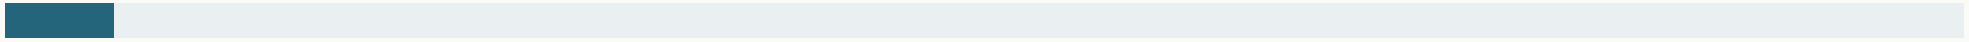
高兴类召回率

88.28% → 78.67%



七类宏平均

67.02% → 66.46%



两条色带按同一尺度表示下降量；只看平均分，容易低估具体类别的变化。

论文方法的不足：覆盖和标签质量仍需检查

边缘均衡，交叉群体仍可能缺失

人数	年轻	年长
女性	50	0
男性	0	50

预设4种组合，只观察到2种。

人口标签来自模型预测

预测误差会影响指标；
缺少主体ID，难以排查主体泄漏。

年龄被当作离散类别

名义变量指标不区分年龄组的远近，
无法利用年龄的顺序信息。

覆盖不足先补数据；有样本但比例失衡时，再探索重加权。

重加权尝试：估计权重，再限制与归一

设置：高兴类中，女性约占10%，男性约占90%。

1. 按群体×类别估计并截断

$$\widetilde{w}_{gy} = \min\left(\frac{p(y)}{Kp(g,y)}, 5\right)$$

最终权重：女性高兴约5，男性约0.56。

2. 类内归一，保持类别总权重

$$w_{gy} = \frac{\widetilde{w}_{gy} n_y}{\sum_{g'} n_{g'y} \widetilde{w}_{g'y}}$$

K=2；n为训练计数。缺失单元无法靠权重补齐。

$$\mathcal{L} = \frac{1}{N} \sum_i w_{g_i y_i} \ell(f_\theta(x_i), y_i)$$

额外训练3个模型，每个20轮。截断值在测试前固定；归一化后最大权重可略高于5。

女性组平均表现提高，男性组略有下降

指标	普通训练	重加权	变化
女性 / 高兴	82.1%	83.1%	+0.99个百分点
男性 / 高兴	88.5%	86.3%	-2.25个百分点
女性 / 宏平均	66.0%	66.7%	+0.64个百分点
男性 / 宏平均	65.5%	64.8%	-0.61个百分点

有效样本量约保留80%。有收益，也有群体间取舍，不能只挑改善项。

代码演示：三份实验Notebook

编号	Notebook内容	主要验证工作
01	二十个真实数据集完整指标复现	17类指标、作者对照与局部矩阵
02	真实人脸表情识别模型训练验证	132次训练、召回率与配对对照
03	不足分析与改进探索	交叉覆盖、标签敏感性与重加权

VS Code已连接 bias-repro-gpu，直接打开 /workspace/notebooks。

代码与注释、已完成的训练日志、分组召回率和真实模型曲线。

本次复现说明了什么

1 论文的指标计算和主要统计分析可以重现。

2 真实训练支持论文的主要定性描述，具体降幅仍有差别。

3 重加权改变了群体表现，需要同时报告收益和代价。

下面留两个问题，分别讨论数据偏差与模型表现。

问题一

男性和女性各占50%，
能说明数据集没有人口统计偏差吗?

请结合表征偏差与刻板偏差讨论。

答案一：总体比例均衡，还要看类别内组成

样本数	高兴	愤怒
女性	50	0
男性	0	50

男女总数相同，
性别与表情仍然完全关联。

还要检查其他人口属性
以及交叉群体是否缺失。

ENS / SEI 描述覆盖和比例；V / Z 描述与标签的关联。

问题二

把重加权后的V降到0，
就能保证模型对每个群体都更好吗？

请区分数据分布与模型测试表现。

答案二：数据分布改变，不保证每个群体都改善

V描述人口属性与标签的统计关联，不直接约束模型错误率。

女性高兴：82.1% → 83.1%

男性高兴：88.5% → 86.3%

判断改进效果，还要看：独立测试集、各群体各类别表现、
整体准确率、群体覆盖和有效样本量。

进一步讨论因果公平时，还需要额外的因果假设。