数据偏差，怎样量化？
从论文复现到缓解探索

Metrics for Dataset Demographic Bias
A Case Study on Facial Expression Recognition

20 个真实公开数据集 / 17 类指标 / 容器内离线验证

先核对论文身份：以 PDF 正文为准

正文实际研究的是数据集人口偏差

Dominguez-Catena 等； TPAMI 2024； arXiv:2303.15889v2 。

文件名与链接都存在容易串题之处

文件名写 Counterfactual Fairness；连字符仓库对应另一篇 2022 年论文。

正确仓库包含完整匿名统计数据

Dataset_Bias_Metrics （下划线）；固定 commit，保留作者原码与许可证。

汇报对象是 PDF 实际正文；反事实实验属于本组扩展。

验证范围：把做到的和未做到的都讲清楚

论文部分	本次交付	验证状态
Sec.III 指标体系	17 类指标， U 双方向	独立实现 + 作者数值对照
Sec.V / Fig.2–8	20 数据集、 3 人口组件	全量重算与图表导出
Appendix B	60 套 count / NPMI / Z	完整矩阵与 20 幅总览
Appendix A	四种构造、 11 个比例点	仅列联表与 (a) 指标曲线
Sec.IV / A 下游模型	原图、 FairFace 、 ResNet50	未重跑；无图像及主体信息

完整复现公开元数据上的统计分析；未重跑原图标注与 ResNet50 。

两种偏差，需要两种观察角度

表征偏差：哪些群体缺失或不足?

只看人口属性边缘分布 $p(g)$，无需表情标签。

刻板偏差：某些群体是否集中在某些表情?

看人口属性与表情标签的联合分布 $p(g,y)$，并与 $p(g)p(y)$ 比较。

边缘均衡，不保证联合独立

男女总体各一半，仍可能“女性多 happy、男性多 angry”。

人口比例、统计依赖、模型公平性是三个不同问题。

17 类指标：用少量可解释指标覆盖主要信息

类别	指标族	关键解释
表征： 10 类	R, ENS, H, D, 1/D, 1−D, SEI, NSD, IR, BP	ENS = exp(H) ， 等效均衡组数
全局： 5 类	Cramér V, T, C, Theil U, NMI	U 计算双方向；衡量统计依赖
局部： 2 类	NPMI, Ducher Z	逐个群体 × 表情单元定位不足 / 超额

$$ENS = \exp[-\Sigma\, p(g) \ln p(g)] \qquad SEI = H / \ln R \qquad V^2 = (\chi^2/n) / \min(r-1, c-1)$$

论文推荐： ENS + SEI 、全局 V 、局部 Z 。

验证设计：避免“跑出一张图就算复现”

第一层：可手算反例与边界测试

独立、完全关联、单组退化、零联合概率、尺度不变性。

第二层：独立公式与固定作者原码交叉核验

1,280 项标量 / 矩阵比较全部通过；不改作者源码。

第三层：直接对照论文印刷结果

Fig.3 / Fig.5 逐项核验；保留舍入容差和聚合约定。

作者代码一致，只是证据之一；还要核对公式与论文数值。

数据与环境：拿到容器即可离线重跑

20
真实匿名数据集

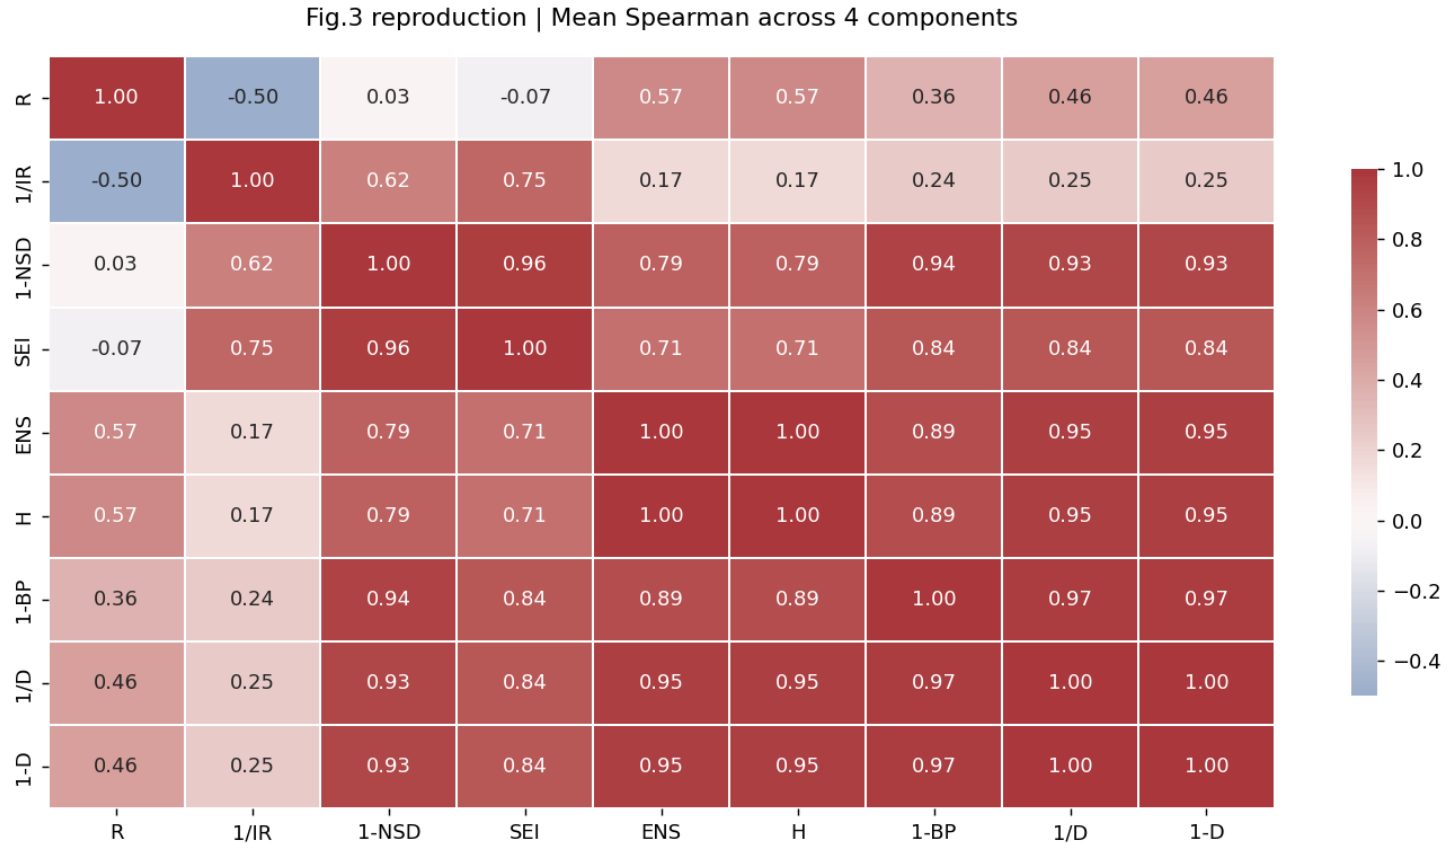
794,166
完整有效记录

3
中文注释 Notebook

nvidia/cuda:12.5.1-base-ubuntu20.04
uv 创建 /workspace/.venv · Python 3.11.15 · uv.lock 固定全部依赖
数据、 Notebook 、 HTML 、图表、 PPT 与讲稿全部打包

CUDA 基镜像中运行 CPU 统计任务；验证不依赖 GPU 。

表征指标：一致性高，但 R 与 IR 是例外



ENS 与 H

ρ = 1.000

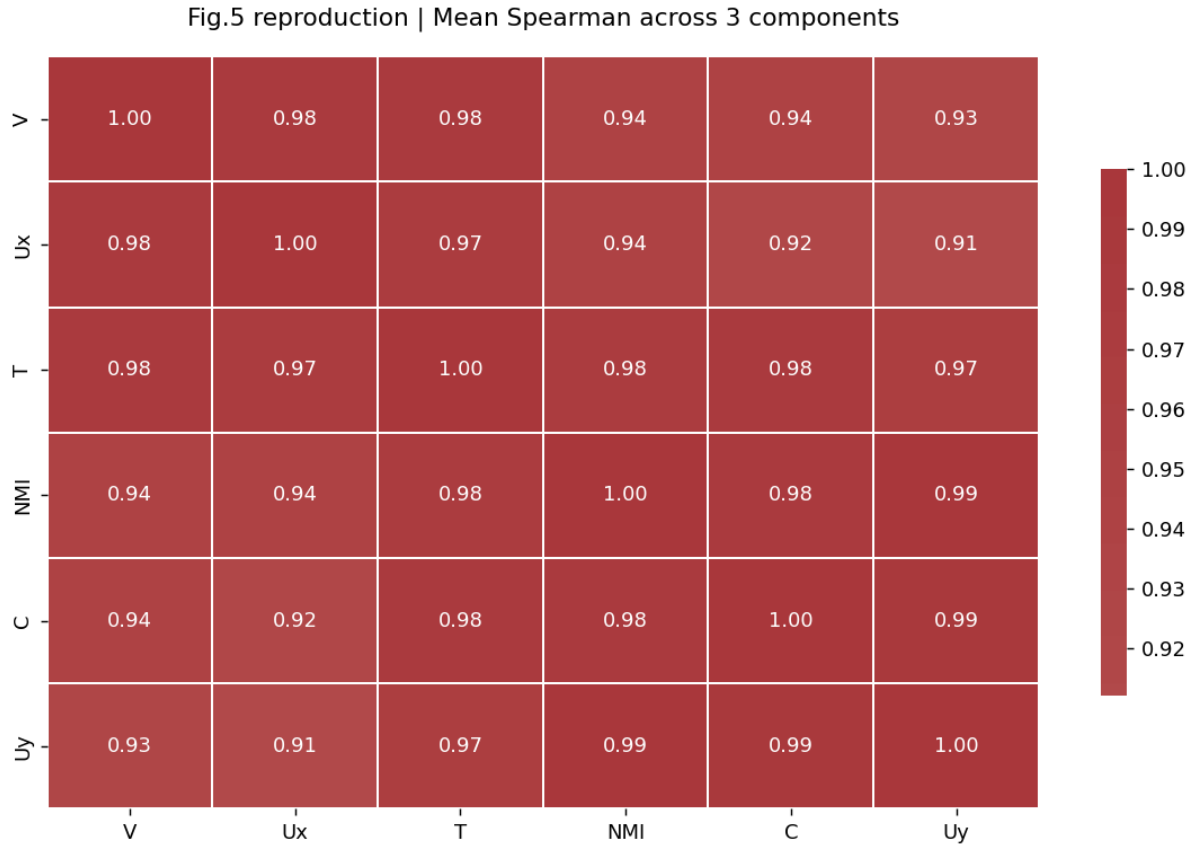
SEI 与 1−NSD

ρ = 0.961

同向相关，不等于相同含义。

复现 Fig.3：先在四组件内相关，再平均；退化相关填 0 的约定另有敏感性说明。

全局刻板偏差：六种读数的排序高度一致



5 类指标

U 取双方向

Fig.5 上三角

21 / 21 印刷项吻合

按熵分母明确 U 的方向。

论文 Eq.(13) 与源码方向不同； Ux=I/H(G)， Uy=I/H(Y)。

局部偏差： Z 指出具体哪些组合失衡



红色：超额出现

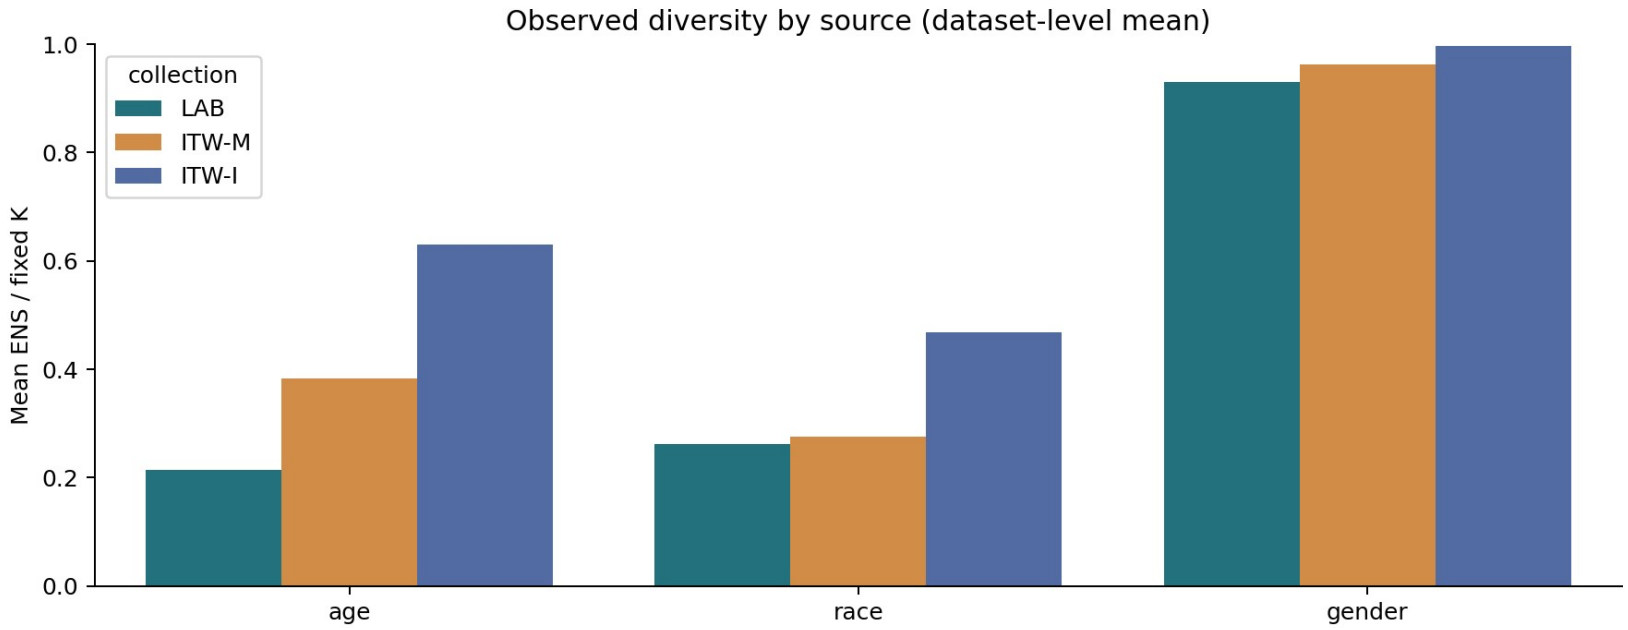
蓝色：不足出现

这张表描述训练数据，不能代替模型错误率。

其他 20 数据集完整矩阵均随包。

局部相关高；完全独立表中的浮点微差会制造伪排序，需要并列处理。

数据来源影响偏差形态，但不是因果结论



LAB： 实验室

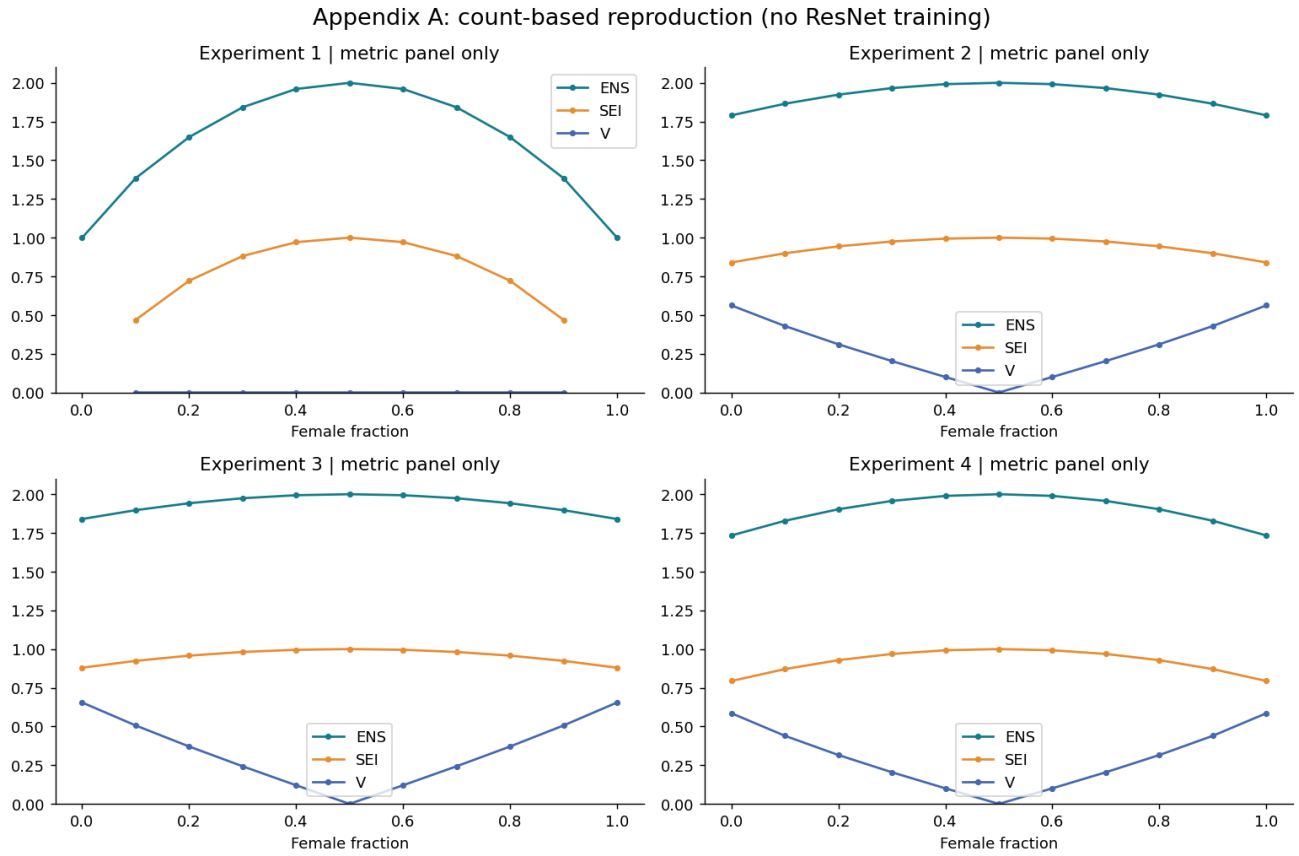
ITW-M： 影视

ITW-I： 互联网

总体观察：互联网数据的表征多样性通常更高。

更高多样性不保证较低刻板偏差；群体标签仍是自动估计的代理。

附录四种偏差：先验证受控构造本身



1 全局比例

2 只改变 happy

3 happy/angry 反向

4 happy/angry 同向

11 个比例点 × 4 。

复现 Fig.9–12(a) 指标面板；未重跑 (b)(c) 的真实模型 recall 。

发现的问题：定义边界比“多一个指标”更关键

公式与源码的差异可以用反例核验

Pearson C 的分母印成 $1-\chi^2/n$； Theil U 的分母方向与函数命名不同。

观测组均衡可能掩盖群体缺失

单组 IR=1；两个边缘均匀，但交叉群体可能只出现 2/4 。

统计关联不提供模型或因果公平保证

自动人口标注存在误差；无主体 ID；数据偏差与模型偏差不必线性对应。

区分排版错误、代码语义差异与研究方法局限，不把它们混成“论文错误”。

改进方案：覆盖审计 → 支持检查 → 有约束缓解

固定标签空间与交叉群体覆盖率

同时报告 R/K 、 ENS/K 、 H/log K ；没有样本的单元单独标记。

不确定性与人口标签噪声敏感性

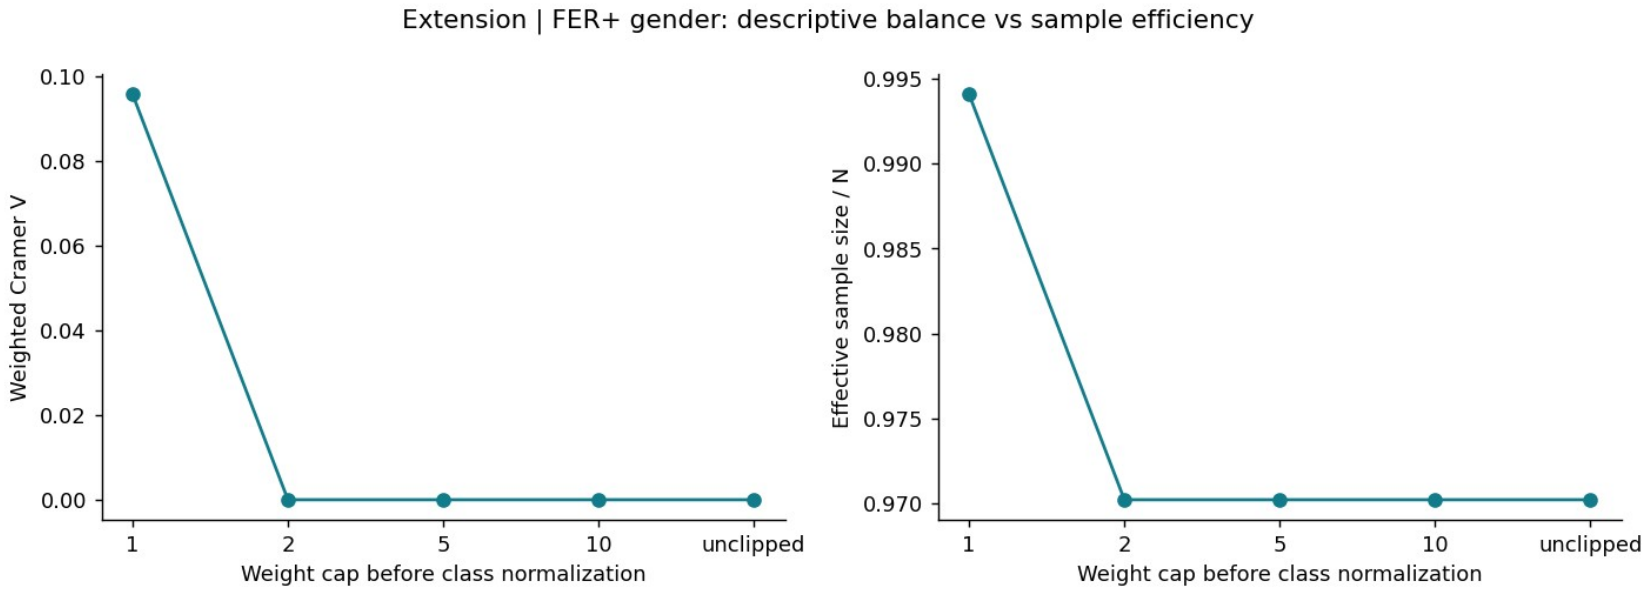
300 次 bootstrap ；校正 V ；扰动代理标签，检查结论稳定性。

保留类别分布的截断重加权

目标 $q(g,y)=p(y)/K$ ；先限权重，再按类别归一；同时报告 ESS 。

无支持单元不能靠加权补出来；统一比例目标也需要场景依据。

真实元数据探索：依赖下降，代价是有效样本量



FER+ / gender

原始 V = 0.1710

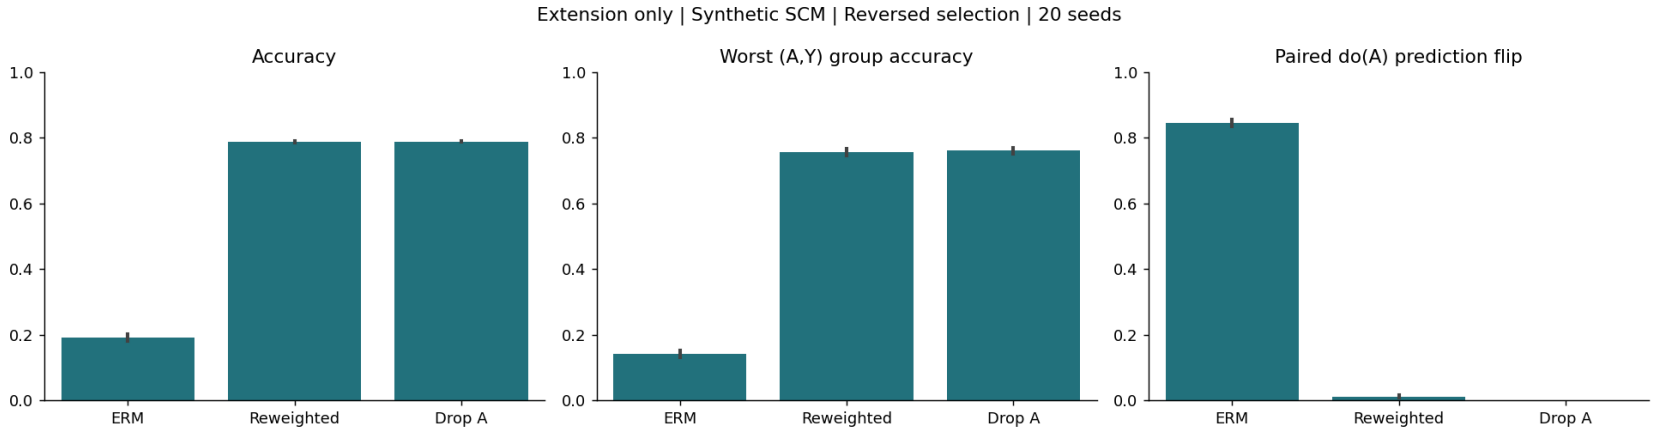
未截断 V ≈ 0

ESS / N = 97.0%

结果是加权统计量，原始记录未改变。

V 降到 0 是目标分布的代数结果；不能据此宣称真实 FER 模型公平。

合成下游：缓解选择偏差，但付出同分布精度代价



反转环境准确率

ERM 19.2%

重加权 78.8%

同分布：

ERM 95.3%

重加权 79.0%

20 个随机种子；训练集估计权重；共享测试样本；明确 SCM 的 do(A) 配对实验。

哪些结论仍然不能从本次实验推出？

不能声称真实模型已达到反事实公平

没有原始图像、主体划分和真实因果图；合成收益不能直接外推。

不能声称重加权总是优于原始训练

同分布精度可能降低；罕见单元会放大方差，缺失单元无解。

下一步实验协议是明确的

主体级划分；同款 ResNet50/20 epochs/1cycle ；三次重复；报告 subgroup recall 。

本次交付覆盖可由公开证据支持的验证，并保留进一步原图实验的清晰接口。

现场演示：从一个命令到可检查结果

① 导入随包镜像

```
docker load -i dist/fer-bias-repro-image.tar.gz
```

② 运行完整复现

```
docker run --rm --network none fer-bias-repro:1.0 reproduce
```

③ 打开交互验证

```
bash scripts/open_lab.sh
```

禁网、无 GPU 、无项目挂载的新容器，独立重跑三个 Notebook 。

对照评分要求：每个结论都有交付证据

完整性与可理解性

范围矩阵、四个研究问题、带中文注释 Notebook 、论文数值对照。

可运行性

离线镜像、 uv.lock 、哈希验证、禁网新容器重跑日志。

不足、方案与探索

公式审计与交叉反例；覆盖 / 不确定性 / 重加权；真实元数据与合成模型实验。

原文复现、方法审计、改进探索分开呈现，所有结果可追溯。

讨论与提问

数据集偏差可以被可靠地量化。
缺失群体、支持条件和因果假设，
决定量化结果能怎样用于缓解。

可现场查验：三个 Notebook / 原始 CSV / 结果表 / 容器运行记录

问题一

男性和女性各占 50%，
就能说明数据集没有人口统计偏差吗？

先讨论，再翻页查看参考答案。

答案一：不能，只能说明性别总体比例均衡

示例 / 人数	高兴	愤怒	合计
女性	50	0	50
男性	0	50	50

表征偏差与刻板偏差要分开看

总体男女各一半，
性别与表情仍可完全关联。

年龄、种族及交叉群体，
也可能缺失或不足。

组合使用 ENS / SEI 、全局 V 与局部 Z ，检查覆盖、比例和联合分布。

边缘比例均衡 ≠ 人口属性与任务标签独立；还需检查其他属性与交叉群体。

问题二

将重加权后的 V 降为 0，
就能证明模型实现反事实公平吗?

先讨论，再翻页查看参考答案。

答案二：不能，数据分布独立不等于反事实公平

V 衡量数据分布中的统计依赖

V=0 不直接约束模型预测；其他特征仍可能含敏感属性的代理。

反事实公平需要明确因果假设

需定义干预敏感属性时哪些变量随之改变，再检查个体的预测变化。

本次扩展的结论有明确范围

合成 SCM 的假设不能直接外推；真实模型仍需保留测试集评估。

重加权还受缺失单元、有效样本量和同分布精度代价约束。